Gated attention

Обучаемый sigmoid-gate регулирует выход attention.

Gate после SDPA, перед выходной проекцией

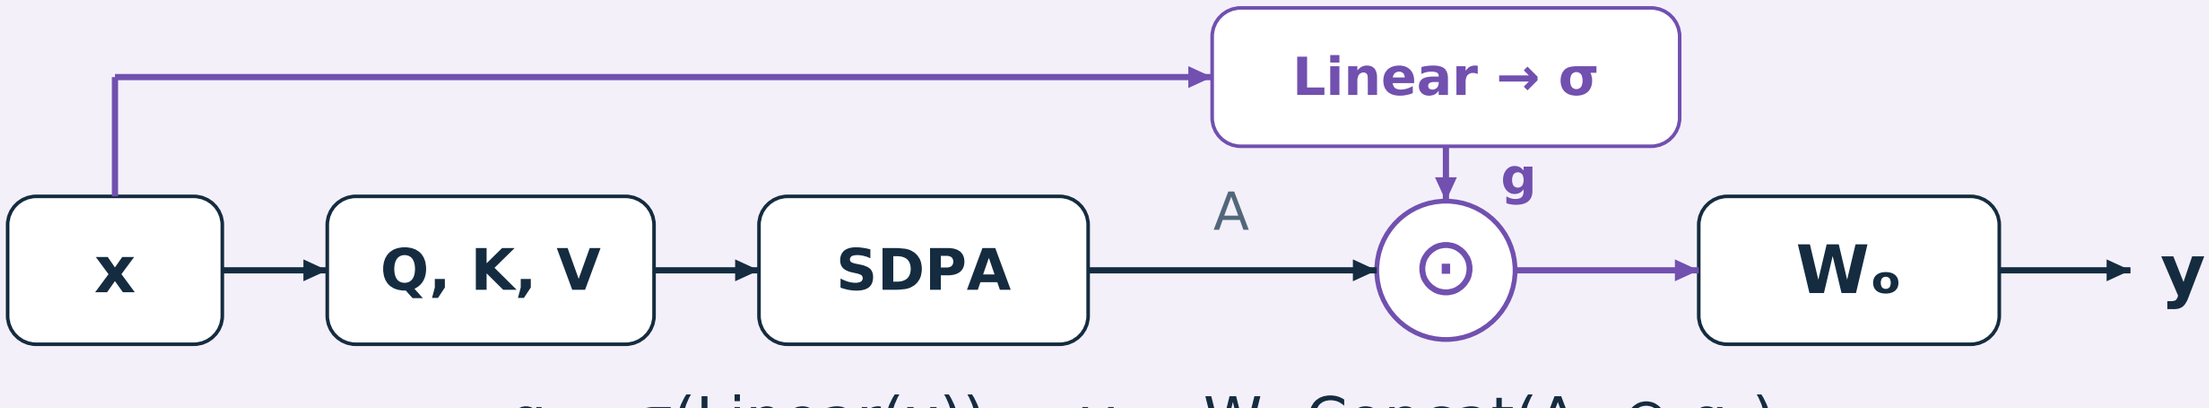

$$g = \sigma(\text{Linear}(x)) \qquad y = W_o\ \text{Concat}(A_h \odot g_h)$$

Headwise

Один gate на голову и токен.

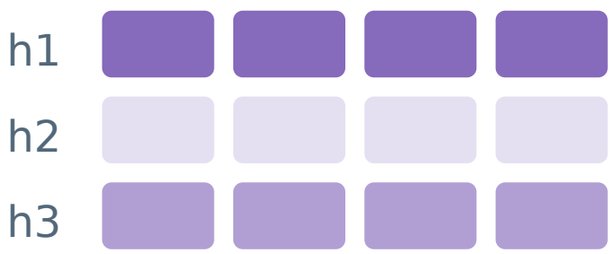

$g_h \in (0, 1)$

Elementwise

Один gate на координату и токен.

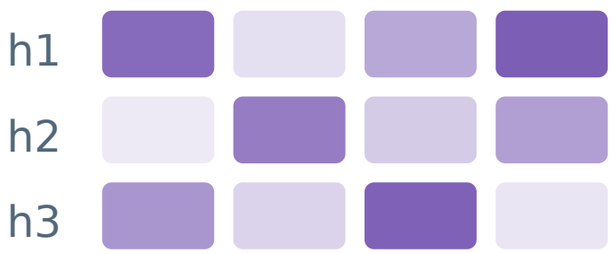

$g_h \in (0, 1)^{d_h}$

g ≈ 0: подавить выход • g ≈ 1: сохранить выход

Qiu et al. · Gated Attention · arXiv:2505.06708