RoPE

Позиция токена задаёт угол поворота Q и K.

Поворот каждой пары координат

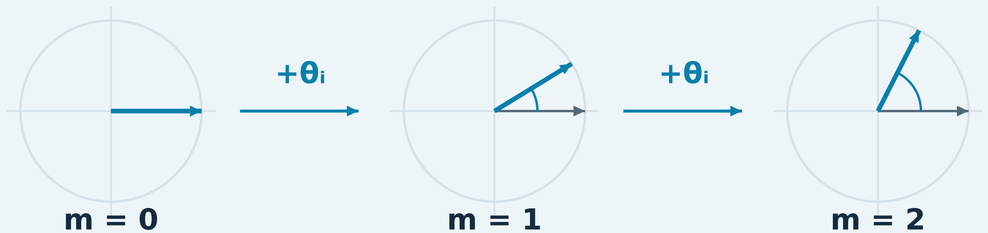

Одинаковый вектор показан в трёх позициях.

$$q'_m = R_m\, q_m \qquad k'_n = R_n\, k_n$$

Пары координат (2i, 2i + 1) поворачиваются на угол $m\theta_i$.

$$\theta_i = 10000^{-2i/d_h}$$

• V без поворота • 0 обучаемых параметров

$$(q'_m)^T k'_n = q_m^T\, R_{n-m}\, k_n$$

Позиционный вклад зависит от n − m.

Su et al. · RoFormer · arXiv:2104.09864

Gated attention

Обучаемый sigmoid-gate регулирует выход attention.

Gate после SDPA, перед выходной проекцией

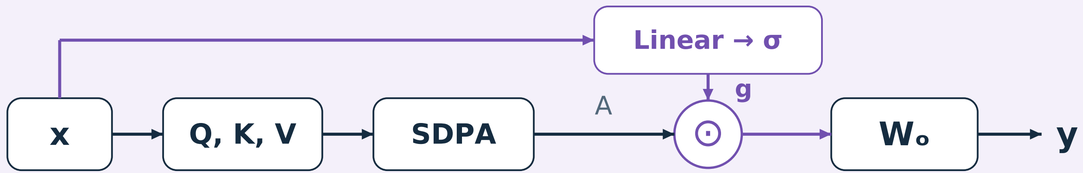

$$g = \sigma(\mathrm{Linear}(x)) \qquad y = W_o\, \mathrm{Concat}(A_h \odot g_h)$$

Headwise

Один gate на голову и токен.

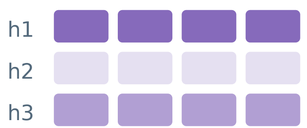

$g_h \in (0, 1)$

Elementwise

Один gate на координату и токен.

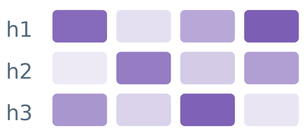

$g_h \in (0, 1)^{d_h}$

g ≈ 0: подавить выход • **g ≈ 1: сохранить выход**

Qiu et al. · Gated Attention · arXiv:2505.06708